REAL or NOT?

NLP 를 통한 자연재해 트윗 분류

이지은, 김동언, 나승주, 백광현

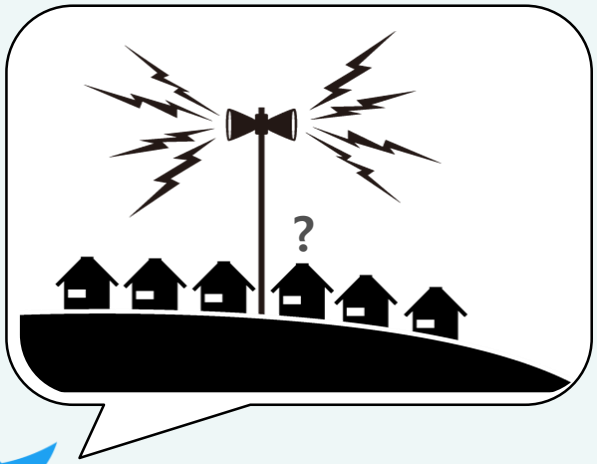

목 차

01
프로젝트 선정 배경

업데이트된 BERT 기반 NLP 를 실험하기 위함

02
프로젝트 개요

프로젝트 timeline 및 사용기술 소개

03
데이터 탐색/정제

시각화 기반 주어진 자료 탐색 및 학습에 필요한 문자열 변환

04
데이터 분석 / 딥러닝

기초 모델과 BERT 모델을 통한 기계학습 수행

05
학습결과 / 개선사항

Confusion Matrix 를 통한 결과값 비교

프로젝트 선정 배경

트윗 의미 구분을 통한 BERT 성능측정

Kaggle 주최 대회에서 양질의 데이터 확보

- 데이터수집에 대한 애로사항 없이 처리/분석에 집중가능
- 트위터 내용 중 재해 관련된 트윗을 학습하여 예측하는 Competition 선정해 수행

[Competition 개요]

True True False True True

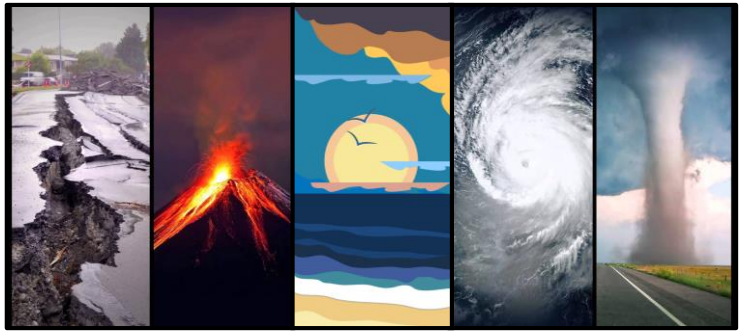

BERT 개요

BERT는 NLP 의 전이학습을 가능하게 함

- BERT 는 Bidirectional Encoder Representations from Transformers 의 약자
- 구글이 개발한 신경망 기반 자연어 학습 알고리즘(2018.11 오픈소스로 공개)
- 기존 모델과 달리 단어 전후의 맥락을 고려한 유추가 가능
- 보강된 알고리즘을 토대로 기존 모델 대비 성능 개선이 용이함

[기존 모델과 BERT 학습방식 비교]

예) I accessed the _____ account

I accessed the *'bank'* (기존모델)

I accessed the *'bank'* account (BERT)

프로젝트 Timeline

2020/3/9 ~ 3/12

기초적인 데이터 분석 과제 수행을 학습하기 위해 Titanic 예제 스터디

2020/3/13

NLP 과제 수행 위한 workflow 및 필요 기술 정립

2020/3/16~3/20

데이터 전처리 및 일반 모델링과 BERT 를 통한 workflow 실현

2020/3/23~3/30

모델별 성능 비교 후 BERT 세부 튜닝 집중

2020/3/31

과제 제출 및 발표

프로젝트 활용기술

Python 3

데이터 파악/처리

01

데이터 탐색(EDA)

- numpy, pandas, matplot, seaborn

02

데이터 전처리

- nltk, re, string, gensim

데이터 분석/모델링

03

일반 ML, 일반 신경망

- sklearn, keras, sequential

04

BERT

- tensorflow, tensorflow_hub

데이터 탐색(1/4): 데이터 파악

훈련데이터 트윗 분류현황

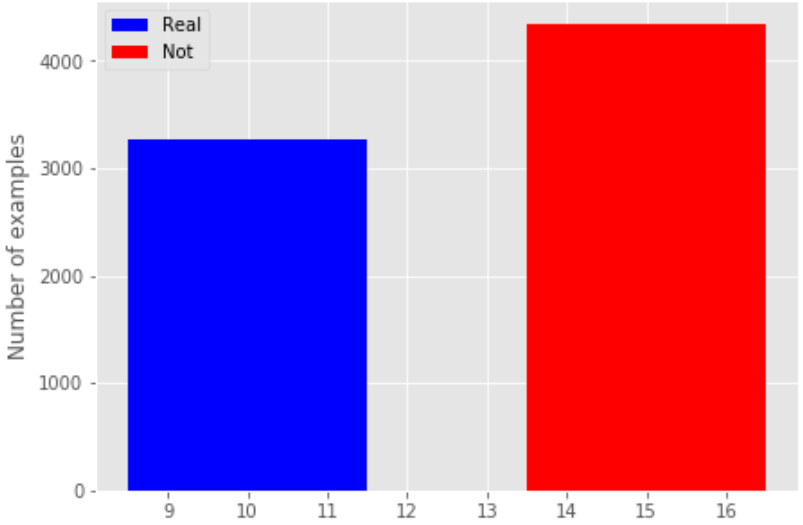

7,613개 Target 값 비중은 3:4 로 비등한 수준임

훈련데이터 트윗 글자수 분포

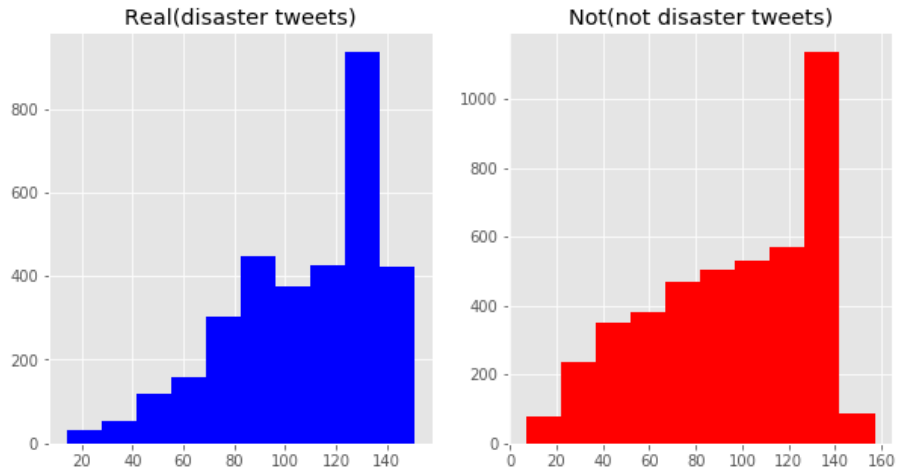

단어 길이 분포 유사함

데이터 탐색(2/4): 길이 파악

훈련데이터 트윗 평균 단어수

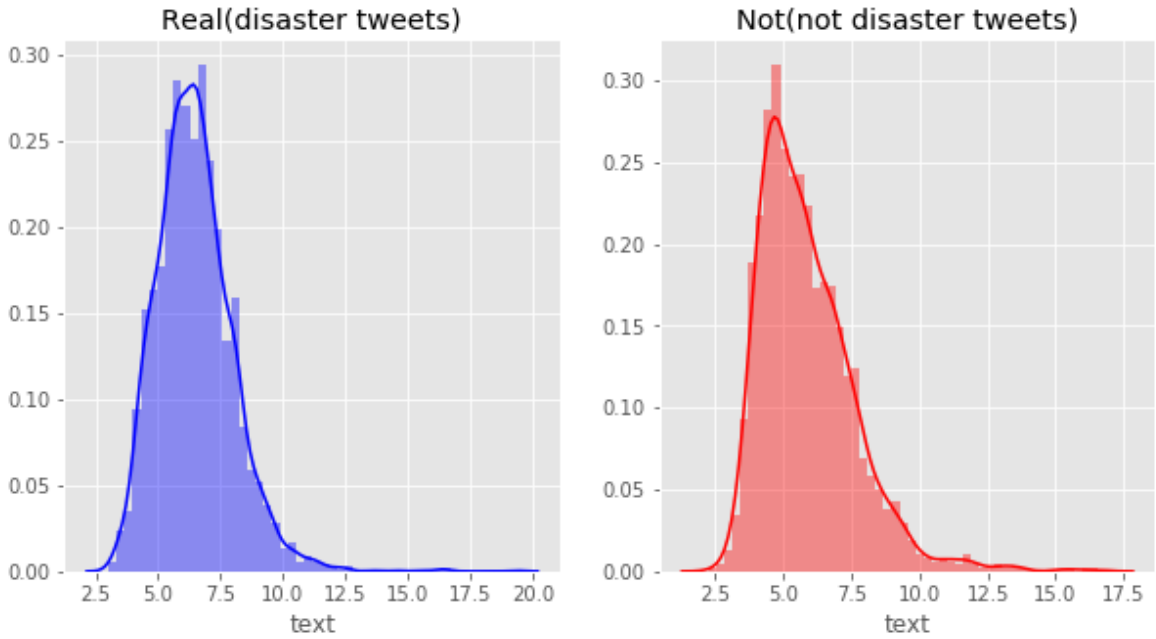

트윗당 단어 갯수 분포 유사함

데이터 탐색(3/4): stopwords, 특수문자 분포 파악

훈련데이터 내 stopwords, 특수문자 분포 현황

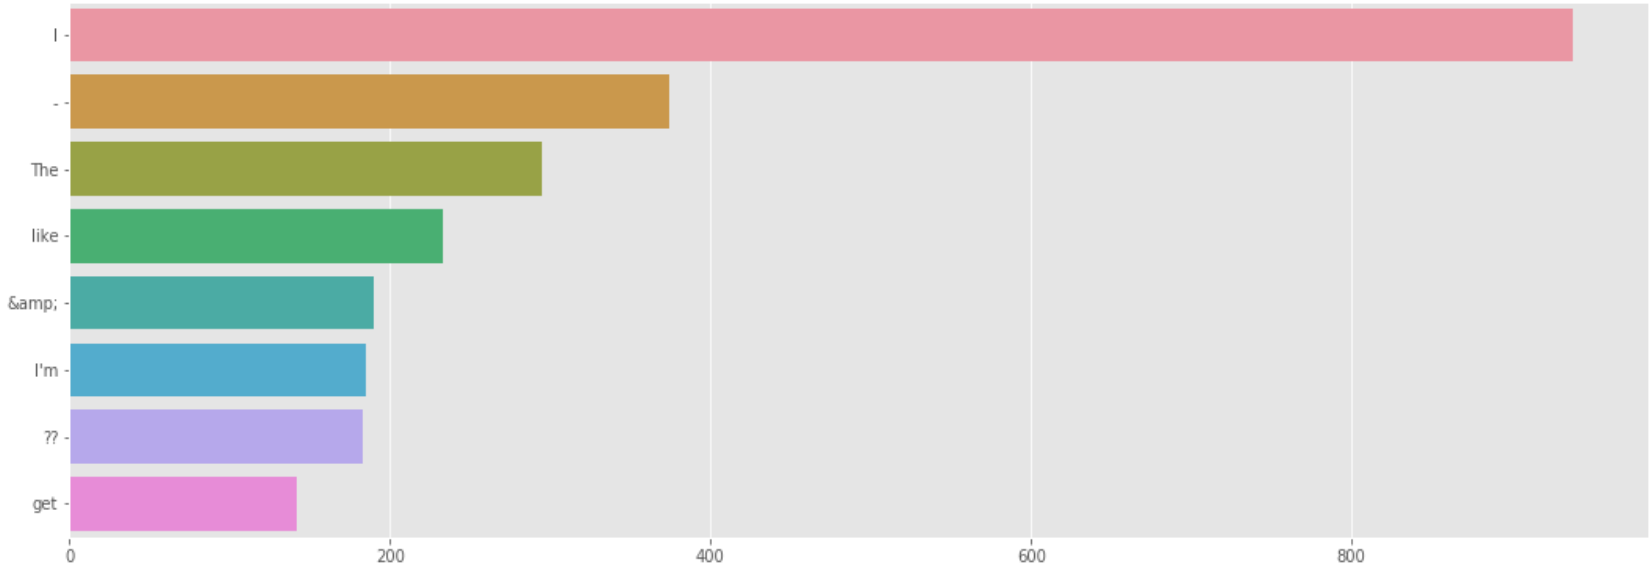

대명사, 관사, 문법부호, HTML 태그 및 줄임말 표현이 존재하므로 필터링 필요

데이터 탐색(4/4): n-gram 분석

훈련데이터 내 두 단어로 구성되어 의미가 불명확한 문자열 분포 현황

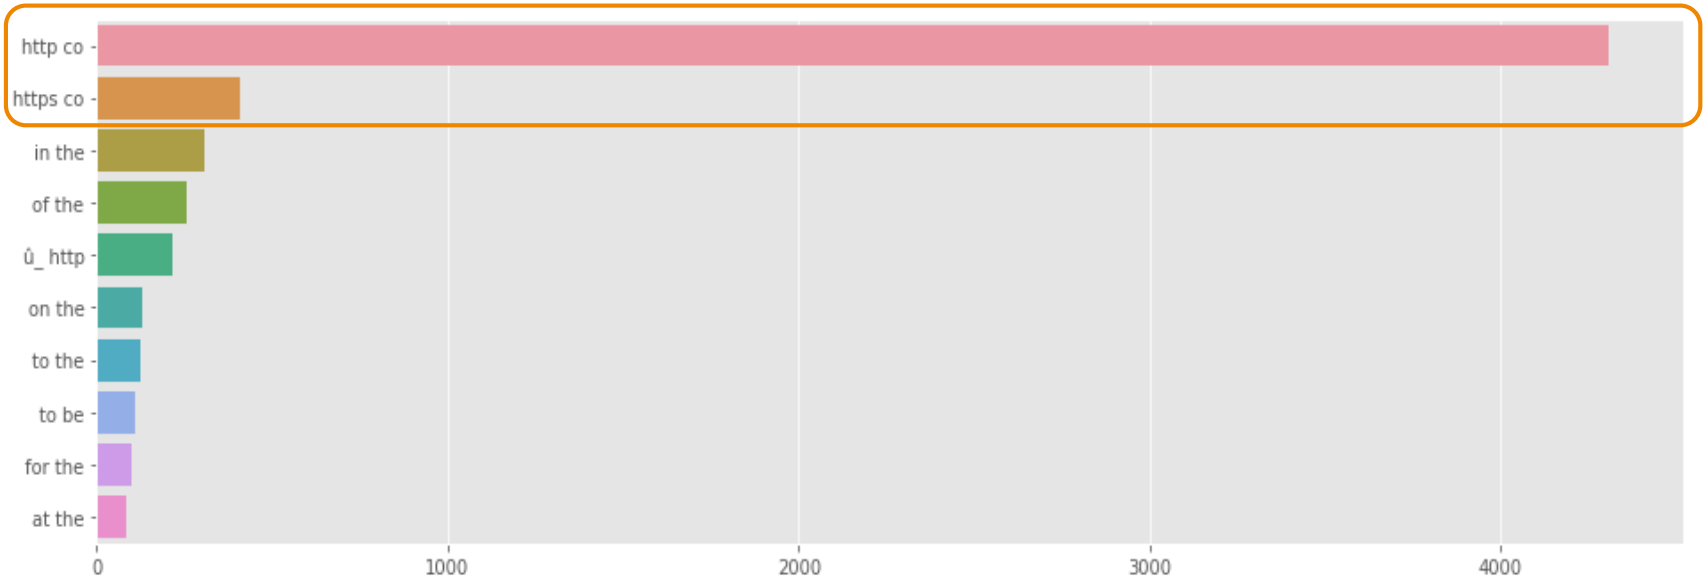

url 구성 표현이 존재하여 일련의 단어 전부 필터링 필요

데이터 정제(1/4): Pre-processing

필터링 대상 선정

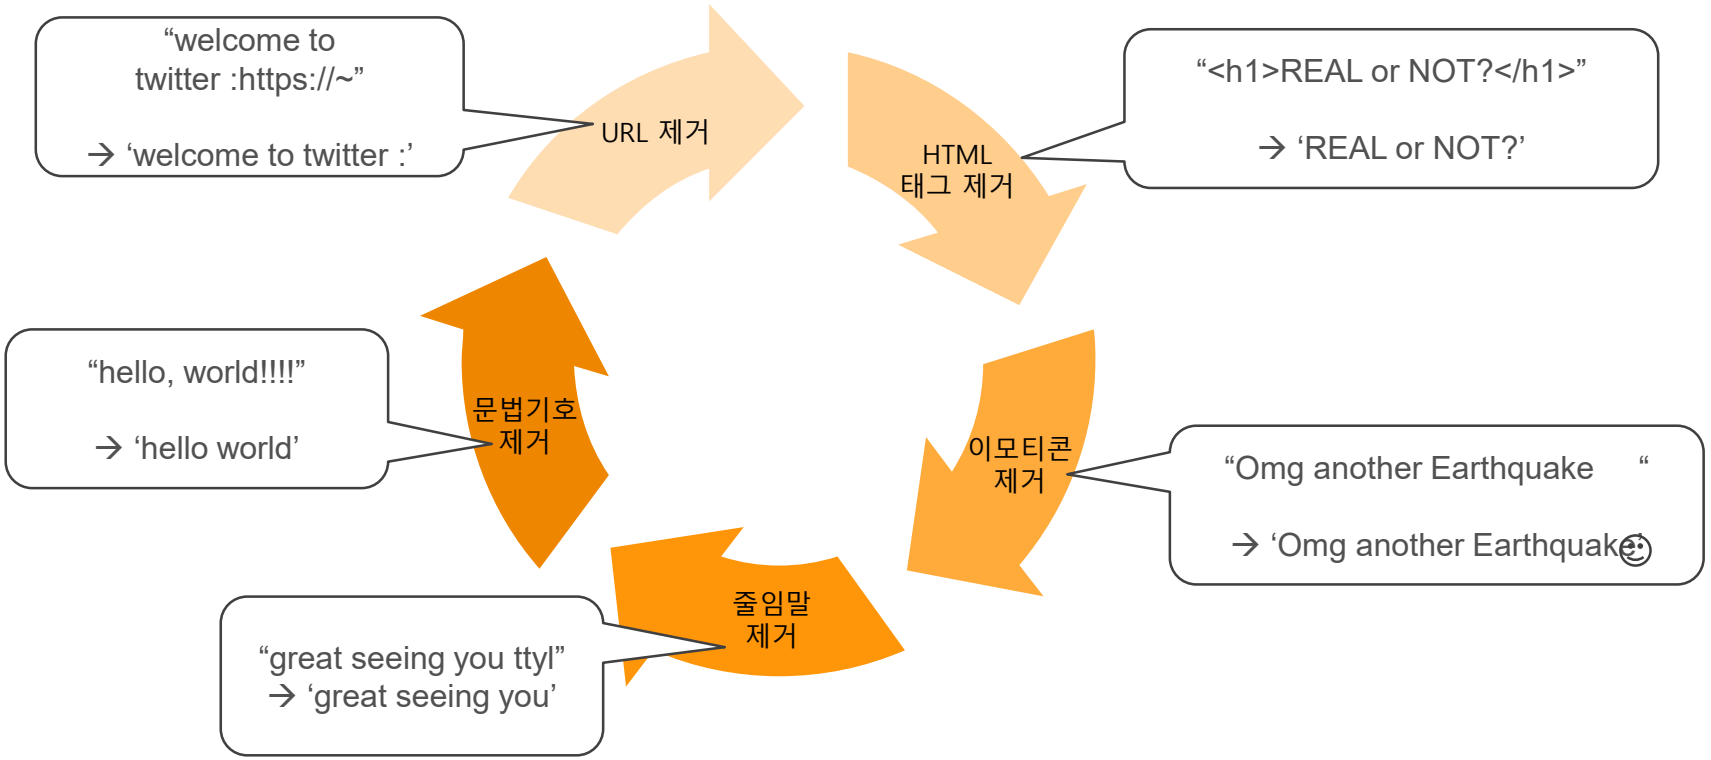

데이터 정제(2/4): Pre-processing

필터링 대상 선정

```
def remove_URL(text):
    url = re.compile(r'https?://\S+|www\.\S+')
    return url.sub(r'',text)
```

URL 제거

HTML 태그 제거

```
def remove_html(text):
    html=re.compile(r'<.*?>')
    return html.sub(r'',text)
```

```
def remove_punct(text):
    table=str.maketrans('','',string.punctuation)
    return text.translate(table)
```

문법기호 제거

이모티콘 제거

```
def remove_emoji(text):
    emoji_pattern = re.compile("["
                               u"\U0001F600-\U0001F64F"  # emoticons
                               u"\U0001F300-\U0001F5FF"  # symbols & pictographs
                               u"\U0001F680-\U0001F6FF"  # transport & map symbols
                               u"\U0001F1E0-\U0001F1FF"  # flags (iOS)
                               u"\U00002702-\U000027B0"
                               u"\U000024C2-\U0001F251"
                               "]+", flags=re.UNICODE)
    return emoji_pattern.sub(r'', text)
```

임말 거

```
abbreviations = {
    "$" : " dollar ",
    "€" : " euro ",
    "4ao" : "for adults only",
    "a.m" : "before midday",
    "a3" : "anytime anywhere anyplace",
```

```
def convert_abbrev(word):
    return abbreviations[word.lower()] if word.lower() in abbreviations.keys() else word
```

```
def convert_abbrev_in_text(text):
    tokens = word_tokenize(text)
    tokens = [convert_abbrev(word) for word in tokens]
    text = ' '.join(tokens)
    return text
```

데이터 정제(3/4): 차원 축소

CountVectorization

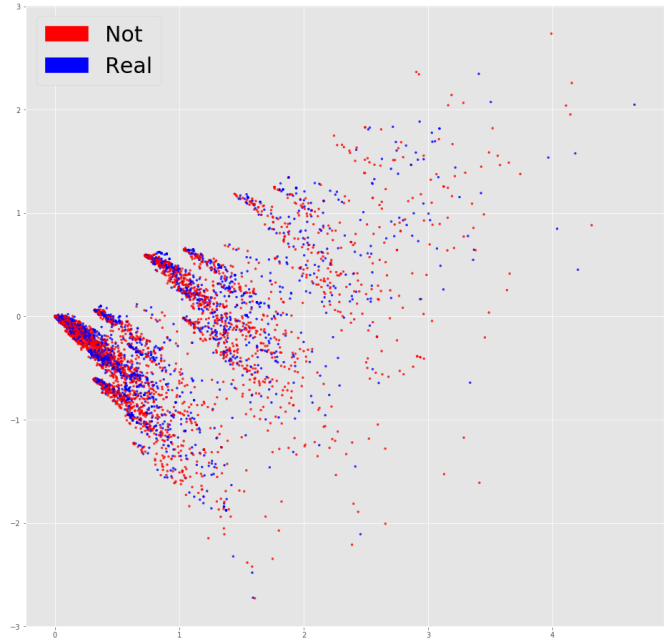

분포가 고르지 않아 단어간 유기성 낮음

TF-IDF

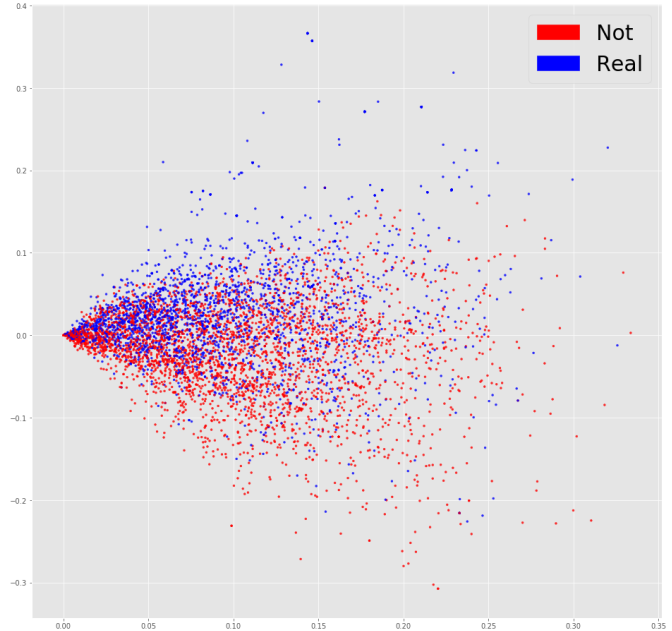

빈도수에 따른 영향력을 측정해 반영

데이터 정제(4/4): GloVe 적용

GloVe 개요

GloVe 는 전체 단어를 분석하는 일에 최적화됨

- GloVe 는 Global Vectors for Word Representation 의 약자임
- 비지도 학습을 통해 문자열 데이터의 벡터화를 수행
- Word2vec 대비 유추 작업 성능은 떨어지나 단어 전체를 고려한 분류 작업 성능이 뛰어남
- 영문 위키피디아 DB 를 통해 사전학습 후 훈련데이터 학습 진행

GloVe 적용 결과

[TF-IDF]

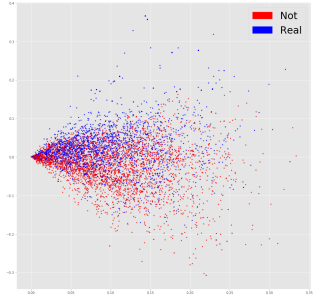

[GloVe]

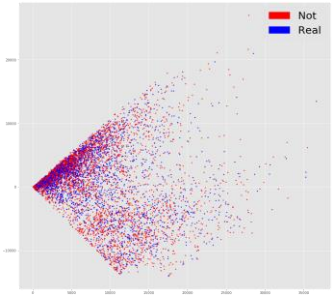

[기초 RNN 통한 두 데이터 적합도 비교]

차원축소 방식	TF-IDF & LSTM	**GloVe & LSTM**
Accurcay	0.5708	**0.7810**
Val_accuracy	0.5686	**0.8050**

데이터 분석: 일반 ML 모델링 (Logistic Regression)

Logistic Regression 개요

범주형 결과값의 분류를 위한 회귀분석

- 독립변수의 선형 결합으로 종속변수를 설명하는 점에서는 선형 회귀분석과 유사
- 다만 일반 선형 회귀와 달리 결과가 특정 분류로 나누어짐
- 분류값의 성공 확률을 종속변수로 정의 후 로짓변환으로 구현

(a) $\text{odds ratio} = \dfrac{p(y=1|x)}{1-p(y=1|x)}$

(b) $\text{logit}(p) = \log \dfrac{p}{1-p}$

(c) $p_i = \text{logit}^{-1}(\boldsymbol{\beta} \cdot \mathbf{X}_i) = \dfrac{1}{1+e^{-\boldsymbol{\beta} \cdot \mathbf{X}_i}}$

적용 결과

[Logistic Regression_코드]

```
lr_clf = LogisticRegression(max_iter=150,
                            penalty='l2',
                            solver='lbfgs',
                            random_state=0)
lr_clf.fit(X_train_onehot, y_train)
lr_pred = lr_clf.predict(X_val_onehot)
```

[Logistic Regression_요약]

F-measurement	0.6537
Accuracy	0.7931
Val_accuracy	0.7214

데이터 분석: 기초 Sequential 모델링 (GloVe + Keras)

Keras 개요

Keras 의 Sequential 모델링을 통해 신경망 baseline 모델 생성

- Keras 는 Sequential 과 Functional 모델 두 분류로 구성됨
- 전자는 전통적인 신경망 구조로 간단한 코딩으로 모델 구현 가능
- 후자는 다중 입/출력값 및 레이어 재활용 가능함
- 단어를 단일 벡터로 치환시켰으므로 Sequential 모델링을 통한 단순 RNN 적용
- GloVe 통해 사전학습된 데이터를 입력

적용 결과

[Sequential_코드]

```
model=Sequential()

embedding=Embedding(num_words,100,embeddings_initializer=Constant(embedding_matrix),
                    input_length=MAX_LEN,trainable=False)

model.add(embedding)
model.add(SpatialDropout1D(0.2))
model.add(LSTM(100, dropout=0.2, recurrent_dropout=0.2))
model.add(Dense(1, activation='sigmoid'))


optimzer=Adam(learning_rate=3e-4)

model.compile(loss='binary_crossentropy',optimizer=optimzer,metrics=['accuracy'])
```

[Sequential_요약]

F-measurement	0.7494
Accuracy	0.7883
Val_accuracy	0.8109

데이터 분석: BERT 모델링 - Baseline

BERT 구현

논문에 공표된 BERT 권장 사양 적용

- Pooling 없이 CLS 토큰(BERT 유형) 단일 적용
- Dense layer (FC layer) 없이 BERT 마지막 층에 반응함수(Sigmoid) 추가
- 학습률, epochs, optimizer 및 batch 크기 고정
  - 학습률 : 2e – 5 ~ 5e – 5
  - Epochs = 3
  - Adam
  - Batch 크기 = 16
    - 원래 32 이나 Kaggle Notebook 사양 (GPU 15.2GB)에 맞추어 16으로 축소 조정

적용 결과

[BERT_코드]

```
# Baseline 하이퍼패러미터
random_state_split = 7
Dropout_num = 0
learning_rate = 3e-5
valid = 0.2
epochs_num = 3
batch_size_num = 16
target_corrected = False
target_big_corrected = False
```

```
checkpoint = ModelCheckpoint('model_BERT.h5', monitor='val_loss', save_best_only=True)

train_history = model_BERT.fit(
    train_input, train_labels,
    validation_split = valid,
    epochs = epochs_num, # recomended 3-5 epochs
    callbacks=[checkpoint],
    batch_size = batch_size_num
)
```

[BERT_Baseline_요약]

F-measurement	0.8442
Accuracy	0.8772
Val_accuracy	0.8339

1차 학습 결과

Summary

모델명	Logistic Regression	GloVe (Sequential)	**BERT**
F-measurement	0.6537	0.7494	**0.8442**
Accurcay	0.7931	0.7883	**0.8772**
Val_accuracy	0.7214	0.8109	**0.8339**

별도의 튜닝을 하지 않음에도 불구하고 BERT 의 교차검증 정확도가 제일 높음

데이터 분석: BERT 모델링 – 세부 튜닝

세부 튜닝 과정

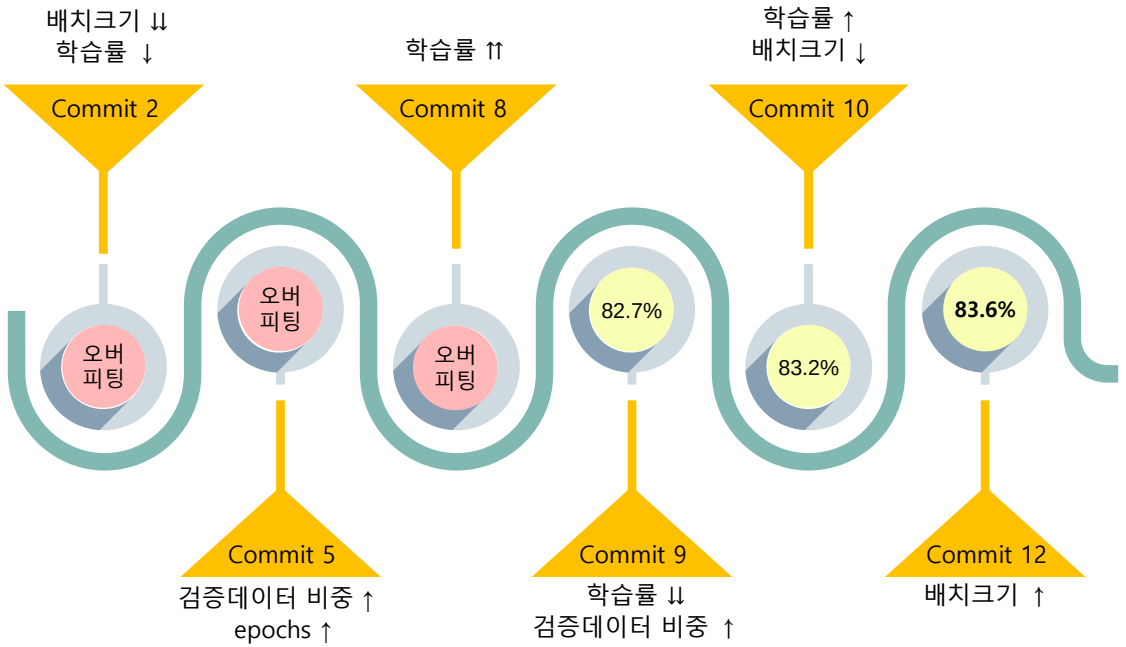

적정 epochs 및 검정데이터 비중 결정하여 오버피팅 제어 후, 학습률 미세 조정으로 성능 향상

개선 사항

추가 DB 확보를 통한 성능 개선

- Tweepy 라이브러리를 활용해 트위터 API 접속
- JSON 기반으로 데이터 수령 가능함
- 대회 DB 양식에 맞게끔 가공하여 추가 학습 진행 가능

[Tweepy API (https://www.tweepy.org/)]

[Tweepy 를 활용한 Twitter API 접속 개요]

```
# 패키지 적용
import tweepy

# 접속권한 정보 설정
access_token = [redacted]
access_token_secret = [redacted]
consumer_key = [redacted]
consumer_secret = [redacted]

# 접속권한 인증
auth = tweepy.OAuthHandler(consumer_key, consumer_secret)
auth.set_access_token(access_token, access_token_secret)
# JSON 처리 패키지
import json

# 저장파일명
tweets_data_path = 'tweets.txt'

# 트윗내용 저장하기 위한 리스트
tweets_data = []

# 접속 시작
tweets_file = open(tweets_data_path, "r")

# 트윗 스트림 읽기
for line in tweets_file:
    tweet = json.loads(line)
    tweets_data.append(tweet)

# 접속 종료
tweets_file.close()
```

Thank You!

데이터 탐색 관련

- N-gram
- NLP 임베딩 작동원리 및 필요성
- SVD
- PCA(1)
- PCA(2)
- LSA
- Word2vec vs GloVe
- N-gram(1)
- Co-occurrence 개념
- CountVectorizer vs TF-IDF
- Understanding GloVe

기타 자료

- GloVe 기초
- 약어 처리
- 토픽 모델링
- NLP 기초(1)
- NLP 기초(2)
- 벤치마크 평가지표
- Confusion Matrix
- Checkpoint 기법
- F-measure 개념 정리
- 전이학습

기계학습 관련

- 로지스틱 회귀(1)
- 로지스틱 회귀(2)
- Keras 기초
- Keras 임베딩
- Keras API
- 로지스틱 회귀(2)
- Keras - Sequential(한국어)
- Keras – Sequential vs Functional

BERT 관련

- BERT 개념(1)
- BERT 개념(2)
- BERT 개념(3)
- BERT 기초(1)
- BERT 기초(2)
- BERT 기초(3)
- BERT 기초(4)
- BERT 기초(5)
- BERT 초기사양
- BERT K-Fold
- BERT 튜닝
- How to Fine-Tune BERT for Text Classificati
- BERT 적정 batch 크기